



湘潭大学研究生课程论文

课 程 名 称：机器学习

论 文 题 目：银行客户忠诚度分析

所 在 学 院：数学与计算科学学院

专业、 班级：数学 1 班

姓 名：孔德权

学 号：202521511167

联 系 电 话：18476271360

课 程 教 师：林翠香

完 成 时 间： 2026 年 6 月 10 日

摘要

在金融市场化竞争加剧的背景下，客户流失常态化已成为制约商业银行盈利增长的关键问题，传统经验驱动的客户管理模式效率低下，难以满足精细化运营需求。本文以银行客户忠诚度与流失行为为研究对象，基于客户资产、活跃度、交易行为等多源数据，构建了客户流失预测模型。研究过程中，首先对数据集进行清洗与特征工程，构建交叉衍生特征以挖掘客户行为与资产状态的耦合关系；随后分别采用随机森林、XGBoost 与 LightGBM 三类算法开展对照实验，并通过混淆矩阵、ROC 曲线与 AUC 值评估模型性能。实验结果表明，LightGBM 模型在流失客户召回率、F1 分数及 AUC 指标上表现最优，有效解决了传统随机森林模型对少数类样本识别不足的问题，实现了较高的预测精度。

关键词：商业银行；客户流失预测；随机森林；LightGBM

目 录

第 1 章 引言.....	1
1.1 研究背景.....	1
1.2 研究内容与研究方法.....	1
第 2 章 算法介绍.....	2
2.1 随机森林算法原理.....	2
2.1.1 基尼系数.....	2
2.1.2 随机森林整体求解流程.....	3
2.2 XGBoost 算法原理.....	3
2.3 LightGBM 算法原理.....	4
2.4 评价指标.....	5
2.4.1 混淆矩阵的定义.....	5
2.4.2 衍生评价指标公式.....	5
2.4.3 指标解读.....	6
第 3 章 数据预处理与可视化.....	6
3.1 数据来源与说明.....	6
3.1.1 数据来源.....	6
3.1.2 数据说明.....	6
3.2 短期数据.....	8
3.2.1 数据预处理.....	8
3.2.2 可视化分析.....	9
3.2.3 小结.....	12
3.3 长期数据.....	12
3.3.1 数据预处理.....	12
3.3.2 可视化分析.....	13
3.3.3 小结.....	16
第 4 章 银行客户长期忠诚度预测.....	16
4.1 特征指标的构建.....	16
4.2 银行客户长期忠诚度预测建模.....	18
4.2.1 特征选取与实验设计.....	18
4.2.2 模型构建过程.....	19
4.3 模型评估与结果分析.....	19
4.4 部分预测结果展示.....	20
第 5 章 不足与改进.....	21

5.1 随机森林预测模型的不足	21
5.2 模型改进措施	21
参考文献.....	24

第1章 引言

1.1 研究背景

随着国内金融业市场化进程持续加速，互联网理财平台、民营银行及各类金融科技公司凭借灵活的产品设计、便捷的服务体验与高收益预期，持续分流传统商业银行的存量客户，市场竞争已从单纯的产品竞争转向客户关系的精细化运营。在此背景下，客户流失呈现常态化、高频化趋势，直接压缩了商业银行的存贷款业务规模与中间业务收入，对银行的长期盈利能力与市场份额构成严峻挑战。因此，如何实现客户忠诚度的精细化管理，精准识别高流失风险客户并开展针对性挽留运营，已成为商业银行维持市场竞争力的核心刚需^[1]。

传统商业银行的客户流失管理，长期依赖客户经理的人工经验进行主观甄别与判断，这种模式不仅主观性强、效率低下，而且难以捕捉客户行为背后的隐性流失信号，容易出现误判、漏判等问题，导致挽留策略滞后、营销资源浪费。随着大数据与机器学习技术在金融领域的深度应用，依托客户多维度数据构建量化流失预测模型，已成为行业主流技术手段^{[2][3][4]}。客户忠诚度的高低，直观体现在短期产品认购意愿与长期账户留存状态两方面：短期忠诚度主要依托营销回访、产品购买等数据体现客户的即时偏好；而长期忠诚度则需要综合客户资产规模、账户活跃度、征信情况、产品持有结构等多维度数据，通过建模分析判断客户的潜在流失概率^[5]。

商业银行客户数据具有来源多、维度杂、非线性关联强的特点，传统统计分析方法难以有效挖掘客户行为与流失之间的复杂规律。利用客户多源数据搭建机器学习预测模型，能够深度挖掘客户流失的隐性特征与行为模式，提前锁定高流失风险客户，为银行的定向营销、客户挽留与差异化运营提供数据支撑，从而有效降低客户损耗成本，提升客户生命周期价值^{[6][7]}。

本次实验依托银行短期营销回访数据集与长期客户资产信息数据集，围绕客户忠诚度量化工具分析与流失预测展开系统性研究。研究流程覆盖数据清洗、可视化探索、特征工程、对照建模与模型评估全环节，通过构建衍生特征挖掘客户行为与资产状态的耦合关系，同时采用随机森林、XGBoost、LightGBM 三类主流算法开展对比实验，筛选出适配银行客户流失场景的最优模型。研究成果可为商业银行客户忠诚度管理提供量化工具与决策依据，助力银行实现从经验驱动到数据驱动的客户运营模式转型，提升客户挽留效率与精细化管理水平。

1.2 研究内容与研究方法

1. 短期数据集：完成缺失、重复数据清洗，借助相关性热力图、分组柱状

图、饼图、箱线图开展客户行为可视化，挖掘年龄、职业、通话时长对短期产品购买（短期忠诚度）的影响规律。

2. 长期数据集：按照户龄、账户余额分层，结合活跃度、信用卡指标构造业务派生特征。

3. 建模实验：采用随机森林训练三组模型，控制模型参数与数据集划分规则不变，仅改变输入特征。

4. 模型评价：基于混淆矩阵、精确率、召回率、F1、AUC 多指标横向对比，筛选最优模型完成测试集预测输出。

第 2 章 算法介绍

2.1 随机森林算法原理

随机森林是以 CART 决策树为基学习器、基于 Bagging+随机子空间的集成算法，最先是由 Breiman 于 2001 年正式提出^[8]，依靠双重随机抽样优势有效缓解单决策树过拟合缺陷，后续被大量落地于金融客户分类场景^[9]。Vafeiadis 等对比朴素贝叶斯、SVM、决策树、集成算法在银行流失数据集效果，证实集成模型适配混杂类型特征与不平衡样本在银行客户流失预测场景应用广泛，可以兼容连续、0-1 离散混合特征^[10]。

2.1.1 基尼系数

设样本集合 D ，二分类标签 $k \in 0,1$ （0=留存，1=流失）， p_k 为类别 k 样本在 D 中占比，基尼不纯度：

$$Gini(D) = \sum_{k=0}^1 p_k(1 - p_k) = 1 - \sum_{k=0}^1 p_k^2.$$

若某特征分裂将 D 拆分为 D_1 、 D_2 两个子节点，则分裂后加权基尼系数：

$$Gini_{split}(D) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2).$$

节点分裂优化目标：遍历全部候选特征与分割阈值，选取是的分裂后基尼 $Gini_{split}(D)$ 最小的特征作为最优分裂特征^[11]，即：

$$\min_{feature, threshold} Gini_{split}(D).$$

算法通过最小化节点加权基尼不纯度，逐层递归划分决策树，直至满足停止分裂条件（节点样本过少或者基尼趋近于 0）。

2.1.2 随机森林整体求解流程

随机森林通过双重随机策略生成独立决策树，集成步骤为：

1. 样本随机。Bootstrap 自助抽样：对原始训练集 N 条样本，有放回随机抽取 N 个样本作为单棵决策树训练集，未被抽中样本为袋外数据(OOB)；
2. 特征随机。随机子空间：单棵树分裂时，从全部 M 个特征中随机选取 $m(m < M)$ 个候选特征，在候选特征内求解最优基尼分裂；
3. 基树生成。重复上述两步，循环生成 $n_{estimators} = 150$ 棵独立 CART 分类树（本实验超参）；
4. 集成投票（求解预测结果）。输入待预测样本，全部决策树独立输出类别，多数投票法则确定最终分类结果：

$$\hat{y} = \operatorname{argmax}_{k \in \{0,1\}} \sum_{i=1}^{150} I(y_i = k),$$

$I(\cdot)$ 为指示函数，第 i 棵树预测为 k 则取值 1，否则 0，得票最多类别为最终预测标签。

2.2 XGBoost 算法原理

XGBoost（极端梯度提升算法）是基于梯度提升框架优化的高效集成学习算法，相较于传统梯度提升决策树（GBDT），其在损失函数、正则化策略、迭代优化方式上做了全面升级^[12]，具备更强的拟合能力与泛化能力，是金融二分类预测、风险识别、客户流失预测场景的主流高精度算法。XGBoost 采用串行迭代训练机制，核心思想是每一棵新生成的决策树，均拟合前序所有模型的预测残差，不断修正预测偏差，逐步降低整体模型的预测误差^[13]。

在损失函数设计上，XGBoost 区别于传统 GBDT 的一阶梯度求解，采用二阶泰勒展开拟合损失函数，精准捕捉损失变化规律，损失函数通用公式如下^[14]：

$$L^{(t)} \approx \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t).$$

式中： g_i 为损失函数的一阶偏导数，代表梯度； h_i 为损失函数的二阶偏导数，代表曲率； $f_t(x_i)$ 为第 t 棵决策树的预测输出； $\Omega(f_t)$ 为正则化项，用于抑制模型过拟合。

XGBoost 引入双重正则化约束，包含 L1 正则（权重稀疏约束）与 L2 正则（权重衰减约束），正则化公式为：

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T \omega_j^2.$$

式中： T 为单棵决策树的叶子节点数量， γ 为叶子节点惩罚系数， λ 为 L2 正则系数， ω_j 为叶子节点权重。该机制可有效简化树结构、避免模型过度学习噪声特征，提升泛化能力。

针对本文数据集类别不平衡的问题，XGBoost 支持设置正负样本权重参数 *scale_pos_weight*，通过手动放大少数类（流失客户）的损失权重，强制模型重点学习流失客户的行为特征，改善传统模型偏向多数样本的缺陷。同时，算法支持并行特征分裂计算、缺失值自动处理，适配银行数据特征维度杂、存在少量缺失值、非线性关联强的特点，能够深度挖掘客户特征与流失行为的隐性关联，有效提升预测精度。

2.3 LightGBM 算法原理

LightGBM 是微软团队基于梯度提升框架优化的轻量化、高精度集成算法，在继承 XGBoos 高精度拟合优势的基础上，针对训练效率、特征筛选、样本采样方式进行深度优化，兼顾预测精度与训练效率，是工业界客户流失、风险预测场景的首选算法^[15]。与传统决策树按层分裂的方式不同，LightGBM 采用基于叶子节点的生长策略（Leaf-wise），每次迭代仅分裂增益最大的叶子节点，在同等迭代次数下，能够构建精度更高的树结构，避免层生长策略带来的无效计算与精度损耗。

在梯度计算优化上，LightGBM 创新性提出梯度单边采样策略，针对梯度较小的多数类样本进行随机采样，保留梯度较大、对模型训练增益更高的样本，在大幅减少计算量的同时，保证模型对关键特征与少数类样本的学习能力。同时采用特征捆绑策略，将互斥稀疏特征进行合并，降低特征维度，提升训练速度。

LightGBM 的核心损失函数沿用梯度提升二阶优化逻辑，同时原生支持 *class_weight="balanced"* 类别均衡策略，可根据训练集样本分布自动反向分配样本权重，权重计算公式如下：

$$\omega_k = \frac{N}{K \cdot N_k}.$$

式中： N 为总样本数， K 为分类类别数， N_k 为第 k 类样本数量。该策略完美适配本次客户流失预测的不平衡数据集，有效解决流失客户样本少、特征学习不充分的问题。

相较于随机森林的并行投票集成模式，LightGBM 通过串行残差拟合持续修正预测误差，对数据非线性关系、特征交互关系的挖掘能力更强；相较于 XGBoost，

其训练速度更快、内存占用更低，且对类别特征、衍生特征的适配性更好。

2.4 评价指标

本实验为二分类任务（Exited=1：流失（正例）；Exited=0：留存（负例）），依托混淆矩阵拆解四类预测结果，衍生 Precision、Recall、F1、AUC 四项量化指标。

2.4.1 混淆矩阵的定义

二分类混淆矩阵格式：

$$CM = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

其中：

TN (True Negative, 真负例)：真实未流失(0)，预测未流失(0)；

FP (False Positive, 假正例)：真实未流失(0)，误判流失(1)（错判忠实客户）；

FN (False Negative, 假负例)：真实流失(1)，误判留存(0)（漏判流失客户，银行业务损失）；

TP (True Positive, 真正例)：真实流失(1)，预测流失(1)（成功预警流失）。

混淆矩阵直观展示模型两类错误：FP 错判、FN 漏判，是模型业务缺陷定位的核心工具^{[16][17]}。

2.4.2 衍生评价指标公式

1. 精确率（Precision，查准率）

所有被模型预判为流失的样本中真实流失占比，衡量错判(FP)控制能力：

$$Precision = \frac{TP}{TP + FP}$$

Precision 越高，越少误将忠实客户标记流失，节约银行无效挽留营销成本。

2. 召回率（Recall，查全率）

全部真实流失样本中被成功识别的占比，衡量漏判(FN)控制能力（银行风控核心指标）：

$$Recall = \frac{TP}{TP + FN}$$

Recall 越高，漏识别流失客户越少，客户流失损耗越低。

3. F1-Score（精确率与召回率调和平均，实验核心综合指标）

平衡 Precision 与 Recall，取值[0,1]，越趋近 1 模型综合性能越优：

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

在样本不均衡的流失预测任务中， $F1$ 相较准确率（ Acc ）可以规避多数类样本干扰，客观反映模型性能^[18]。

4. AUC 指标

即 ROC 曲线下面积，取值(0,1)， $AUC > 0.5$ 代表模型具备分类能力，数值越接近 1，模型区分客户是否流失的整体能力越强，不受分类阈值与样本不均衡影响^{[19][20]}。

2.4.3 指标解读

FP 偏大，说明精确率偏低：大量正常客户被误判流失，营销资源浪费。

FN 偏大，说明召回率偏低：大量流失客户未被提前预警，银行客户流失损失严重。

$F1$ 兼顾两类错误，为本实验三组模型横向对比的首要参考指标。

第 3 章 数据预处理与可视化

3.1 数据来源与说明

3.1.1 数据来源

本实验的数据来源于 2022 年（第 5 届）“泰迪杯”数据分析技能赛 B 题：银行客户忠诚度分析，官网链接为：<https://www.tipdm.org:10010/?state=null#/competition/1557899215680741376/question>，也可以通过 github 链接 <https://github.com/kongdequan/324134141.git> 获得这些数据、本文所使用的程序以及本实验报告。

3.1.2 数据说明

本实验数据包括短期客户产品购买数据和长期客户资源信息数据，数据详细情况如表 1 所示。

表 1 附件数据详细情况

数据集	数据名称	备注
短期客户产品购买数据	short-customer-data.csv	客户购买产品的记录数据
长期客户资源信息数据	long-customer-train.csv	训练集数据
	long-customer-test.csv	测试集数据

短期客户产品购买数据记录了往期银行营销活动中客户购买产品的信息，包含客户的基本信息、上次活动后拜访客户信息和上次活动产品购买结果等，具体的数据指标说明如表 2 所示。

表 2 短期客户产品购买数据指标说明

分类	字段	说明
基本数据	user_id	客户 id, 例 BA220001
基本数据	age	年龄 (数字)
基本数据	job	工作类型包含 11 种, 分别为行政人员(adm.), 蓝领(blue-collar)、企业家(entrepreneur)、家政(housemaid)、企业管理层(management)、退休(retired)、个体经营者(self-employed)、服务行业人员 (services)、学生(student)、技术员(technician)、失业(unemployed)
基本数据	marital	婚姻状况包含 3 种, 分别为离婚(divorced)、已婚(married)、单身(single), 注: 离婚指离婚或丧偶
基本数据	education	教育情况包含 5 种, 分别为研究生以上(postgraduate)、高中(high school)、文盲(illiterate)、专科(junior college)、大学学位(undergraduate)
基本数据	default	信用违约情况包含 2 种, 分别为否(no)、是(yes)
基本数据	housing	住房贷款情况包含 2 种, 分别为否(no)、是(yes)
基本数据	loan	个人贷款情况包含 2 种, 分别为否(no)、是(yes)
上次活动后拜访客户信息	contact	联系人通信类型包含 2 种, 分别为蜂窝(cellular)、电话(telephone)
上次活动后拜访客户信息	month	最近一次拜访客户的月份, 分别为一月(jan)、二月(feb)、三月(mar).....十一月(nov)、十二月(dec)
上次活动后拜访客户信息	day_of_week	最近一次拜访客户的星期, 分别为星期一(mon)、星期二(tue)、星期三(wed)、星期四(thu)、星期五(fri)
上次活动后拜访客户信息	duration	最近一次拜访客户的通话时长, 以秒为单位(数字), 如果通话时长=0, 表示没有成功联系上客户
其他属性	poutcome	上一次银行活动, 客户购买产品的结果包括 3 种, 分别为失败(failure)、不存在(nonexistent)、成功(success)
产品购买结果	y	本次银行活动客户购买产品的结果, 分别为否(no)、是(yes)

长期客户资源信息数据记录了往期该银行客户流动状态及客户信息, 包括客户基本信息、客户户龄与金融资产、客户活跃状态与流失情况等, 具体的数据指标说明如表 3 所示。

表 3 长期客户资源信息数据指标说明

序号	字段	说明
1	CustomerId	客户 ID
2	CreditScore	表示信用资格，数值越大表明信用越高
3	Gender	客户性别，0 表示男性，1 表示女性
4	Age	客户年龄
5	Tenure	账号户龄，客户在这家银行存款的时长，以年为单位
6	Balance	AUM，客户的金融资产
7	NumOfProducts	客户购买产品数量
8	HasCrCard	客户持有信用卡状态，客户有信用卡为 1，否则为 0
9	IsActiveMember	客户活动状态，客户处于活跃状态为 1，否则为 0
10	EstimatedSalary	客户个人年收入
11	Exited	客户流失情况，已流失为 1，否则为 0

接下来，本文将分别对短期客户产品购买数据“short-customer-data.csv”（简称短期数据）和长期客户资源信息数据的训练集“long-customer-train.csv”（简称长期数据）进行数据探索与清洗。

3.2 短期数据

3.2.1 数据预处理

表 4 短期数据各字段缺失数量

字段	缺失数量
user_id	0
age	0
job	330
marital	80
education	1730
default	8596
housing	990
loan	990
contact	0
month	0
day_of_week	0
duration	0
poutcome	0
y	0

短期客户原始数据集共包含 41176 条样本、14 个字段，各字段缺失值统计结果如表 4 所示。

对数据的初步探索结果可知，user_id、age、contact、month、day_of_week、duration、poutcome、y 字段无缺失值。job、marital、education、default、housing、loan 字段存在不同程度缺失，其中 default 字段缺失值数量最多，为 8596 条，占原始样本量的 20.88%。

同时，user_id 列存在 56 条重复记录，为保证客户数据唯一性，需对其进行去重处理。

经过缺失值删除与重复值去重后，短期客户数据集剩余 30445 条有效样本、14 个字段。

短期数据中存在 default、housing、loan、y 等字符型二分类字段，取值为{no/是, yes/否}，这类字段无法直接参与后续相关性计算与可视化分析，因此需将其转换为数值型变量，采用 0-1 二值编码规则：将“否”/“no”编码为 0，“是”/“yes”编码为 1，实现字符型数据的数值化转换。

数据处理的最终结果保存在 result1.xlsx。

3.2.2 可视化分析

本节基于预处理后的短期客户数据，通过相关性热力图、分组柱状图、双饼图与箱线图，多维度分析客户特征与银行产品购买行为的关联规律，挖掘短期客户忠诚度特征。




图 1 短期数据特征相关性热力图

从短期数据特征相关性热力图可见，各变量间整体相关性较弱，仅存在一处显著关联：通话时长（duration）与产品购买结果（y）的相关系数为 0.39，呈中等正相关关系。年龄、信用违约、住房贷款、个人贷款等其他特征与产品购买结果的相关系数均在±0.05 以内，几乎无线性关联。

相关性分析表明：通话时长是影响客户产品购买意愿的关键线性因素，通话时间越长，客户购买银行产品的概率越高。而年龄、信贷状态等特征与购买行为的线性关联较弱，后续建模时需重点关注通话时长变量。




图 2 不同年龄段客户产品购买占比分组柱状图

按年龄段分组统计的产品购买占比结果显示：18-30 岁、31-40 岁、41-50 岁、51-60 岁客户的产品购买占比均低于 17%，其中 41-50 岁客户购买率最低，仅约 10%。60 岁以上老年客户的产品购买占比显著高于其他年龄段，达到 45%左右，是购买意愿最强的群体。

年龄对客户产品购买行为存在显著影响：老年客户（60 岁以上）对银行产品的接受度更高、购买意愿更强，短期忠诚度表现突出。而中青年客户群体的产品购买率普遍偏低，是后续营销推广的重点目标客群。




图 3 蓝领（blue-collar）与学生（student）的产品购买情况饼图

蓝领（blue-collar）与学生（student）两类客户的产品购买占比差异显著：蓝领客户的产品购买率仅为 7.97%，超过 92% 的蓝领客户未购买银行产品。学生客户的产品购买率达到 33.33%，是蓝领客户的 4 倍以上，购买意愿远高于蓝领群体。

职业类型是影响客户产品购买行为的重要因素：学生客户对银行产品的接受度和购买意愿明显高于蓝领客户，短期忠诚度表现更优；蓝领客户群体的产品渗透率较低，需针对性设计适配其需求的产品与营销方案，提升客户转化率。




图 4 是否购买与通话时长箱线分布图

以产品购买结果为 x 轴、通话时长为 y 轴的箱线图显示：未购买产品客户的通话时长中位数约为 200 秒，整体分布集中在 0-600 秒区间，仅少量客户通话时长超过 1000 秒。已购买产品客户的通话时长中位数约为 400 秒，整体分布集中在 200-800 秒区间，且存在大量通话时长超过 1000 秒的客户，通话时长整体显著高于未购买客户。

通话时长与客户产品购买行为存在强关联：通话时间越长，客户购买银行产品的概率越高，这与相关性热力图的结论一致。说明营销人员与客户的有效沟通时长是影响客户转化的关键因素，后续营销工作中可通过优化沟通话术、延长有效通话时长提升客户购买率。

3.2.3 小结

综合四组可视化结果，可得出短期客户忠诚度的核心规律：

1. 通话时长是影响客户购买意愿的关键因素，通话时间越长，客户购买产品的概率越高；
2. 老年客户（60 岁以上）和学生客户的产品购买意愿更强，短期忠诚度表现更优；
3. 中青年客户与蓝领客户的产品购买率偏低，是后续营销推广的重点优化群体。

3.3 长期数据

3.3.1 数据预处理

本节针对长期客户数据的字段异常值与业务分层需求，完成数据清洗与特征编码处理，为后续流失因素可视化分析提供标准化数据基础。

长期客户数据的 Age 字段存在两类异常问题：

1. 数值异常：存在-1、0、-等不符合实际年龄范围的数值；
2. 字符异常：包含空格、“岁”等非数字字符，导致字段无法直接转换为数值型变量。

本次处理采用“删除+清洗”结合的方式：

1. 数据读取与异常值删除：读取原始长期客户数据，删除 Age 字段值为-1、0、-的行数据；
2. 字符清洗：将 Age 字段转换为字符串类型，通过正则表达式清除所有非数字字符（包括空格、“岁”等）；
3. 类型转换与二次清洗：将清洗后的 Age 字段转换为数值型变量，删除转换失败（空值）的行数据；
4. 结果保存：将处理完成的数据保存至文件 result2.xlsx。

为进一步挖掘客户流失的分层特征，本文基于账号户龄与客户金融资产两个维度，对 result2.xlsx 的数据按表 5 和表 6 的标准对客户进行分层编码。

表 5 账号户龄划分情况

账号户龄区间	客户状态
[0, 3]	新客户
(3, 6]	稳定客户
>6	老客户

表 6 客户金融资产划分情况

客户金融资产区间	资产阶段
[0, 50000]	低资产
(50000, 90000]	中下资产
(90000, 120000]	中上资产
>120000	高资产

其中客户状态存于“Status”列，资产阶段存于“AssetStage”列，编码结果保存到文件“result3.xlsx”中。

3.3.2 可视化分析

为进一步探究银行长期客户流失的潜在规律，本节基于预处理后的 result3.xlsx 数据集，从客户年龄、信用评分、账户户龄、资产等级与客户状态等维度开展可视化分析，挖掘不同特征下客户的流失差异，为后续流失预测建模提供依据。

1. 年龄段与客户流失关系分析

为避免单一年龄维度数据过于零散，本次将客户年龄划分为 17-30 岁、31-40 岁、41-50 岁、51-60 岁、60 岁以上五个区间，统计各年龄段客户的流失与未流失占比并绘制折线图。




图 5 不同流失状态下各年龄段客户占比折线图

从整体分布可以看出，不同年龄段客户的流失行为存在显著差异。其中，18-50 岁中青年客户群体流失占比较低，整体客户稳定性较强；而 51 岁以上中老年客户流失比例明显上升，成为流失高发群体。整体客户流失趋势呈现“中段稳定、两端抬升”的特征，尤其高龄客户流失风险突出。

从业务角度分析，中青年客户金融需求稳定、忠诚度较高；而老年客户理财需求多元、外部产品选择多，对银行依赖度较低，因此更容易发生流失。银行后续应重点针对高龄客户群体开展专属维护与权益运营，提升留存水平。

2. 年龄与信用评分的流失分布特征分析

以年龄为横轴、信用评分为纵轴，结合客户流失状态绘制散点分布图，可直观观察不同信用水平、不同年龄客户的流失分布规律。




图 6 不同流失情况下信用资格与年龄分布散点图

分析结果表明，客户信用评分整体集中在 400~850 分区间，信用评分与年龄无明显线性相关关系。未流失客户在中高年龄段普遍拥有更高的信用评分，信用状况良好；而已流失客户多集中在中老年区间，且存在大量低信用评分样本。低信用评分的中老年客户风险抵御能力弱、金融活跃度低，是客户流失的重点人群。

由此可知，信用评分可作为客户流失预警的重要辅助指标，低信用分的中老年客户需纳入重点监控名单，提前开展客户维系。

3. 账户户龄与客户流失占比分析

为精准分析不同开户时长客户的留存差异，对账号户龄与流失状态进行交叉统计，结合堆叠柱状图开展分层分析。

从整体数据来看，各户龄段客户的未流失占比均保持在 77% 以上，说明银行整体客户留存情况较好，大部分客户具备长期稳定性。细分来看，户龄为 7 年的老客户流失率最低，仅为 15.85%，忠诚度最高；而户龄 1 年的新客户、户龄 9 年的老客户流失率相对偏高，分别为 22.22%、21.60%，属于流失风险较高的两类群体。




图 7 不同流失情况下客户账号户龄占比堆叠柱状图

从业务逻辑分析，开户初期（1年）客户对银行产品和服务认可度尚未稳固，容易流失；而超长期客户（9年以上）随着服务周期变长，需求逐步变化，若银行未持续跟进服务与产品更新，极易出现客户流失现象。后续需针对新开户客户与超长期存量客户制定差异化维护策略。

4. 客户状态、资产等级与流失量热力图分析

为探究不同客户层级、不同资产规模客户的流失差异，结合客户状态（新客户、稳定客户、老客户）与资产阶段（低资产、中下资产、中上资产、高资产）绘制流失量热力图。

热力图结果显示，客户流失数量与资产规模呈现显著正相关特征。高资产层级的新客户与老客户流失样本数量最多，是流失最严重的群体；而中下资产层级客户整体流失量最少，客户粘性最强。稳定客户群体整体流失情况优于新客户与老客户，客户结构最为健康。

高资产客户掌握更多金融资源，理财选择更广，对服务质量、产品收益敏感度极高，一旦体验不佳极易发生流失，属于银行核心高价值客户，也是重点维稳对象。针对该类客户，银行可推出专属理财、一对一客户经理服务、专属权益等方式，进一步锁定高净值客户。




图 8 新老客户各资产阶段流失客户量热力图

3.3.3 小结

通过多维度可视化分析,可以明确银行长期客户流失的核心特征:年龄偏大、信用评分偏低、开户初期与超长期户龄、高资产规模客户的流失风险显著更高。以上特征有效揭示了客户流失的分布规律,为后续特征工程筛选、流失预测模型构建、银行客户精细化运营策略制定提供了有力的数据支撑。

第 4 章 银行客户长期忠诚度预测

4.1 特征指标的构建

在完成银行客户数据清洗、异常值处理以及客户分层的基础上,为进一步挖掘客户行为与忠诚度的潜在关联,强化后续忠诚度预测模型的精度与泛化能力,本节对本文 3.3.1 数据处理的结果 result3.xlsx 开展特征指标构建工作。原始数据集的基础特征维度较为单一,仅能直观体现客户基础信息与单一行为状态,无法综合反映客户生命周期、资产规模、金融产品使用行为与客户忠诚度的耦合关系。因此,本次结合客户账号户龄分层、资产规模分层结果,搭配客户活跃状态、信用卡持有状态等核心行为指标,交叉构建三项全新衍生特征,从客户生命周期粘性、资产价值活跃度、金融产品持有粘性多个维度丰富数据集特征体系,为后续客户长期忠诚度预测、流失风险研判提供高质量的数据支撑。

本次构建的第一项特征为新老客户活跃程度特征,见表 7,综合客户账号户

龄分层结果与客户活跃状态进行指标重构。其中账号户龄将客户划分为新客户、稳定客户、老客户三类，客户活跃状态分为非活跃、活跃两种状态，通过两类指标交叉组合赋值，形成 0-5 的梯度化特征数值，数值大小对应不同生命周期客户的综合活跃粘性水平，有效区分了不同开户时长客户的活跃度差异，精准刻画客户在银行服务周期内的粘性特征，弥补单一户龄指标或活跃度指标的分析局限性。数据结果存于 “IsActiveStatus” 列。

表 7 新老客户活跃程度特征构建规则

新老客户		活跃状态	
活跃程度		0	1
账号户龄	新客户	0	3
	稳定客户	1	4
	老客户	2	5

第二项构建特征为不同金融资产客户活跃程度特征，见表 8，依托前期划分的低资产、中下资产、中上资产、高资产四类客户资产层级，结合客户账户活跃状态进行交叉赋值建模。该特征取值区间为 0-9，梯度化的数值能够直观反映不同资产规模客户的活跃行为差异，重点凸显了高资产低活跃、低资产高活跃等特殊客户群体的特征区别，可有效捕捉高价值客户的流失潜在信号，精准体现客户资产价值与账户活跃度对长期忠诚度的协同影响。数据结果存于 “IsActiveAssetStage” 列。

表 8 不同存款额客户活跃程度特征构建规则

不同金融资产		活跃状态	
客户活跃程度		0	1
资产阶段	低资产	0	6
	中下资产	1	7
	中上资产	2	8
	高资产	3	9

第三项构建特征为不同金融资产信用卡持有状态特征，见表 9，整合客户资产分层结果与信用卡持有状态，构建差异化赋值指标。信用卡作为银行核心金融产品，客户持有状态直接反映其对银行产品的依赖度与使用粘性，结合资产规模进行特征构建后，可精准区分不同资产层级客户的产品绑定程度，其中高资产、中上资产持有信用卡客户统一赋予最高特征值，体现高价值客户的核心粘性特征，能够有效识别不同资产客户的金融行为偏好与忠诚度差异。数据结果存于 “CrCardAssetStage” 列。

表 9 不同金融资产信用卡持有状态特征构建规则

不同金融资产		活跃状态	
信用卡持有状态		0	1
资产阶段	低资产	0	6
	中下资产	2	7
	中上资产	5	9
	高资产	5	9

通过上述多维度特征构建，本次研究在原始数据基础上完善了特征体系，实现了客户基础属性、资产属性、行为属性的深度融合。所有衍生特征构建完成后，整合原始数据与全新特征形成最终建模数据集，结果保存至 result4.xlsx。

4.2 银行客户长期忠诚度预测建模

长期数据存在“Exited”特征分布不均衡、各项数值分布跨度大等现象。体现为：未流失客户量是已流失客户量的 3 倍以上；客户信用资格最大数值达到 25 万，而客户活动状态则为 0 和 1 等。考虑上述现象，对“long-customer-test.csv”测试数据的银行客户长期忠诚度进行预测，将全部预测结果保存为文件“result5.xlsx”。

4.2.1 特征选取与实验设计

本次采用控制变量法，设计三组对比实验，选取的特征如下：

A 组（基础特征组）：选取 9 个原生基础特征，包括客户信用资格、性别、年龄、户龄、金融资产、客户购买产品数量、持有信用卡状态、活动状态和个人年收入，直接反映客户的基础信息与单一行为状态。

B 组（衍生特征组）：仅使用任务 4 构建的 3 个衍生特征，即 IsActiveStatus、IsActiveAssetStage、CrCardAssetStage，用于验证交叉特征对客户忠诚度的单独表征能力。

C 组（全特征组）：将 9 个原生基础特征与 3 个衍生特征合并，形成 12 个特征的全量数据集，以检验衍生特征对模型整体性能的增益效果。

为保证三组实验的可比性，本次采用固定随机种子与分层抽样的方式划分训练集与验证集，确保三组模型的训练样本与验证样本完全一致，仅特征输入不同。同时，对所有数值特征进行标准化处理，消除量纲差异对模型的影响。

4.2.2 模型构建过程

本次建模采用随机森林分类器（Random Forest Classifier），模型设置如下关键参数：

n_estimators=150: 设置 150 棵决策树，在保证模型泛化能力的同时避免过拟合。

class_weight="balanced": 自动调整类别权重，解决 Exited 变量的类别不平衡问题，提高模型对少数类（流失客户）的识别能力。

random_state=42: 固定随机种子，保证实验结果可复现。

具体建模流程如下：

- 1. 数据预处理：对全量特征数据进行标准化，消除特征间的量纲差异。
- 2. 样本划分：采用分层抽样将数据划分为训练集（80%）与验证集（20%），保持训练集与验证集的类别分布与原数据一致。
- 3. 特征分组：根据三组实验的特征选取方案，从标准化后的全量数据中提取对应特征子集。
- 4. 模型训练：使用同一随机森林模型对三组特征数据分别进行训练，确保模型超参完全一致。
- 5. 模型评估：基于验证集数据，计算混淆矩阵、准确率、精确率、召回率、F1 分数与 AUC 值，对模型性能进行多维度评估。

4.3 模型评估与结果分析

三组实验的模型评估结果如表 10 所示：

表 10 三组实验的模型评估结果

实验组别	准确率 Acc	精确率 Prec	召回率 Rec	F1 分数	AUC 值
A 组	0.8457	0.7456	0.3433	0.4701	0.8369
B 组	0.5978	0.2587	0.5450	0.3509	0.6189
C 组	0.8489	0.7514	0.3624	0.4890	0.8341

- 1. 对混淆矩阵的分析
 - A 组（原生特征组）：混淆矩阵为[[1430, 43], [241, 126]]，其中 TN=1430（正确预测未流失客户）、FP=43（误判为流失客户）、FN=241（漏判的流失客户）、TP=126（正确识别的流失客户）。模型整体准确率较高，但召回率仅为 0.3433，说明模型对流失客户的识别能力较弱，漏判情况较多。
 - B 组（衍生特征组）：混淆矩阵为[[900, 573], [167, 200]]，模型准确率与精确率较低，但召回率提升至 0.5450，说明衍生特征单独使用时，对流失客

户的识别能力更强，但误判率较高，整体稳定性不足。

C 组（全特征组）：混淆矩阵为 $\begin{bmatrix} 1429 & 44 \\ 234 & 133 \end{bmatrix}$ ，相比 A 组，TP 从 126 提升至 133，FN 从 241 下降至 234，说明加入衍生特征后，模型对流失客户的识别能力有所提升，同时保持了较高的整体准确率。

2. 关键指标对比分析

准确率（Accuracy）：C 组（0.8489）略高于 A 组（0.8457），B 组（0.5978）明显偏低，说明仅使用衍生特征无法保证模型的整体预测准确性，而结合原生特征与衍生特征可以实现最佳的整体性能。

精确率（Precision）：C 组（0.7514）略高于 A 组（0.7456），B 组（0.2587）显著偏低，说明衍生特征单独使用时，误判为流失客户的比例较高，而与原生特征结合后，模型对流失客户的预测可信度更高。

召回率（Recall）：C 组（0.3624）较 A 组（0.3433）提升约 5.6%，B 组（0.5450）虽最高但伴随严重的误判问题，说明衍生特征能够有效提升模型对流失客户的识别能力，降低漏判率。

F1 分数：C 组（0.4890）高于 A 组（0.4701）与 B 组（0.3509），说明结合衍生特征的模型在精确率与召回率之间实现了最佳平衡，对流失客户的综合识别能力最强。

AUC 值：A 组（0.8369）与 C 组（0.8341）均保持在 0.83 以上，B 组（0.6189）明显偏低，说明衍生特征单独使用时模型的分类能力较弱，而与原生特征结合后，模型的整体分类性能未出现明显下降，仍保持较高水平。

4.4 部分预测结果展示

随机森林的部分预测结果如表 11 所示。

表 11 部分预测结果

CustomerId	Exited
15579131	0
15674442	0
15719508	1
15730076	1
15792228	1

第5章 不足与改进

5.1 随机森林预测模型的不足

本次研究初期采用随机森林模型开展银行客户长期忠诚度预测，在实际应用中暴露出以下几方面不足，限制了模型对流失客户的识别能力与业务适配性。

首先，模型对流失客户的识别灵敏度不足，漏判问题突出。随机森林在本次数据集上的召回率仅为 0.3597，意味着超过 60% 的真实流失客户未被模型提前识别，大量潜在流失客户无法进入银行的挽留干预流程，直接造成客户流失与业务价值损失。这一缺陷的核心原因在于随机森林的并行集成学习机制，对类别不平衡数据的适配能力有限，在未流失客户占比远高于流失客户的场景下，模型易偏向多数类，导致对少数类样本的特征规律挖掘不充分，难以捕捉客户流失的隐性行为信号。

其次，模型对衍生特征的利用效率较低，特征增益未得到充分体现。尽管在 4.1 节中构建的交叉衍生特征能够反映客户生命周期、资产规模与活跃度的耦合关系，但随机森林模型对高维特征交互信息的挖掘能力有限，未能充分利用衍生特征提升流失客户识别能力，模型整体预测精度仍有较大提升空间。

最后，模型在业务场景中的实用性受限。银行客户流失预测的核心目标是降低客户漏判率，而随机森林模型在追求整体准确率的同时，牺牲了对流失客户的识别能力，其高准确率主要由未流失客户的预测结果支撑，无法满足业务场景中“优先识别高流失风险客户”的核心需求，难以支撑银行开展精细化客户挽留运营。

5.2 模型改进措施

针对随机森林模型存在的不足，本次研究采用梯度提升树算法对模型进行改进，选用 XGBoost 与 LightGBM 两款金融领域主流模型开展对比实验，通过串行迭代拟合残差的方式提升模型对流失客户的识别能力，同时验证衍生特征的实际价值。

改进措施主要包括三方面：一是更换基模型，采用梯度提升树算法替代随机森林，利用其串行训练机制，每一棵新树均拟合前序模型的预测残差，逐步修正模型对流失客户的识别偏差；二是优化类别不平衡处理方式，通过设置样本权重与梯度损失函数调整，加大流失客户样本在训练过程中的损失占比，改善模型对少数类样本的学习效果；三是充分利用全量特征体系，融合原始基础特征与交叉衍生特征，提升模型对客户流失行为规律的挖掘能力。

改进后，模型性能得到显著提升，各模型关键指标对比结果如下：

表 12 各模型指标汇总对比

模型名称	准确率	召回率	F1 分数	AUC
随机森林	0.8473	0.3597	0.4844	0.8346
XGBoost	0.8299	0.5341	0.5560	0.8099
LightGBM	0.8190	0.6106	0.5736	0.8395

从指标对比来看，LightGBM 模型的召回率从随机森林的 0.3597 提升至 0.6104，流失客户漏判率降低近 40%，F1 分数提升至 0.5736，实现了精确率与召回率的均衡优化；同时 AUC 值达到 0.8395，模型对流失与未流失客户的整体区分能力显著增强。XGBoost 模型的召回率提升至 0.5341，F1 分数提升至 0.5560，同样实现了对流失客户识别能力的优化，验证了梯度提升树算法在本场景下的有效性。

为进一步验证改进后模型的性能，本文绘制了 LightGBM 模型的混淆矩阵，对预测结果的分布情况进行直观分析：




图 9 LightGBM 混淆矩阵

混淆矩阵结果显示，LightGBM 模型对未流失客户的正确识别数为 1283，误判为流失的客户数为 190；对已流失客户的正确识别数为 224，漏判为未流失的客户数为 143。结合指标计算结果，模型对流失客户的识别召回率达到 61.04%，说明超过六成的真实流失客户能够被模型提前识别，大幅降低了漏判风险；同时，模型整体预测准确率保持在 81.90%，在业务成本与客户挽留效果之间实现了有效平衡。

此外，本文绘制了随机森林、XGBoost 与 LightGBM 三种模型的 ROC 曲线，

对模型的整体区分能力进行对比验证：




图 10 多模型 ROC 曲线对比图

从 ROC 曲线形态来看，LightGBM 模型的曲线始终位于其他两条曲线的上方，更靠近左上角，说明该模型在任意分类阈值下，都能在较低的误判率下保持较高的流失客户识别率，综合区分能力最优。结合 AUC 值来看，LightGBM 模型的 AUC 达到 0.8395，是三个模型中最高的，表明其对流失客户与未流失客户的整体区分能力最强；随机森林模型 AUC 为 0.8346，区分能力次之；XGBoost 模型 AUC 为 0.8099，区分能力相对较弱。三条模型曲线均显著高于随机猜测基准线，说明模型均具备有效的客户流失预测能力，其中 LightGBM 模型的表现尤为突出。

改进后的模型在保持较高整体预测准确率的同时，大幅降低了流失客户漏判率，契合银行客户流失预测的业务核心需求，能够为银行客户挽留运营提供更精准的决策支持。后续研究中，可通过调优模型超参数、引入时序行为数据等方式进一步提升模型性能，实现对客户长期忠诚度的动态预判。

参考文献

- [1] 胡永培,张琛.基于 AP 聚类与随机森林的客户流失预测研究[J].计算机技术与发展,2021,31(2):49-53.
- [2] 蔡男.基于改进随机森林算法的电信客户流失预测及分析[D].南昌大学,2020.DOI:10.27232/d.cnki.gnchu.2020.003252.
- [3] 甘露.基于因果推断筛选特征的银行客户流失实时预测模型[D].华中科技大学,2024.DOI:10.27157/d.cnki.ghzku.2024.001008.
- [4] 王圣节,张庆红.基于可解释机器学习模型的电信行业客户流失预测研究[J].电信科学,2024,40(7):121-133.
- [5] 许云鹏.基于数据挖掘的手机银行客户流失分析与预测[D].西南大学,2023.DOI:10.27684/d.cnki.gxndx.2023.005584.
- [6] 李龙.基于 DeepFM 神经网络的电信客户流失预测模型优化研究[D].天津科技大学,2024.DOI:10.27359/d.cnki.gtqgu.2024.000088.
- [7] 金钰.基于混合特征选择的商业银行客户流失预测研究[D].华中农业大学,2022.DOI:10.27158/d.cnki.ghznu.2022.001521.
- [8] 周志华. 机器学习[M]. 清华大学出版社, 2016.
- [9] Quinlan J R .Induction of Decision Trees[J].Machine Learning, 1986, 1(1):81-106.DOI:10.1007/BF00116251.
- [10] Breiman.Random forests[J].MACH LEARN, 2001, 2001,45(1)(-):5-32.DOI:10.1023/A:1010933404324.
- [11] 余锦河,田举,丁颖.基于改进随机森林算法的电力金融风险分析方法研究[J].电力信息与通信技术,2023,21(11):63-69.DOI:10.16543/j.2095-641x.electric.power.ict.2023.11.09.
- [12] Pedregosa F , Varoquaux G , Gramfort A ,et al.Scikit-learn: Machine Learning in Python[J].ArXiv, 2011, abs/1201.0490.DOI:10.5555/1953048.2078195.
- [13] Friedman J H .Greedy Function Approximation: A Gradient Boosting Machine[J].Annals of Statistics, 2001, 29(5):1189-1232.DOI:10.2307/2699986.
- [14] Chen T , Guestrin C .XGBoost: A Scalable Tree Boosting System[J].A CM, 2016.DOI:10.1145/2939672.2939785.
- [15] Chawla N V , Bowyer K W , Hall L O ,et al.SMOTE: Synthetic Minority Over-sampling Technique[J].Journal of Artificial Intelligence Research, 2002, 16(1):321-357.DOI:10.1613/jair.953.
- [16] 李田雨 高煌婷 翟亚琪.基于非平衡大数据的公司破产评估模型研究[J].

财经理论与实践, 2025(2).

- [17] 李航. 统计学习方法[M]. 清华大学出版社, 2019.
- [18] 顾明,李飞凤,王晓勇,等.基于改进 SMOTE 算法和深度学习集成框架的信用卡欺诈检测[J].贵阳学院学报(自然科学版),2024,19(2):99-104+115.DOI:10.16856/j.cnki.52-1142/n.2024.02.020.
- [19] Fawcett T .An introduction to ROC analysis[J].Pattern Recognition Letters, 2005, 27(8):861-874.DOI:10.1016/j.patrec.2005.10.010.
- [20] 彭科.基于数据挖掘的银行客户流失预测模型研究与应用[D].四川轻化工大学,2024.DOI:10.27703/d.cnki.gsclg.2024.000388.